

Generación de Grafos de Conocimiento a partir de Documentos en Formato PDF mediante Modelos de Lenguaje Extensos y Procesamiento de Lenguaje Natural

Trabajo Terminal No. 20XX-XXXX

*Alumno: *González Arellano Jesús Ángel*

Directores: Rosas Castillo Ary Shared, Ramírez Morales Mario Augusto

**e-mail: jgonzaleza2102@alumno.ipn.mx*

Resumen – La presente propuesta plantea el desarrollo de un sistema capaz de generar grafos de conocimiento a partir de documentos en formato PDF, empleando Modelos de Lenguaje Extensos (Large Language Models, LLM por sus siglas en inglés) y técnicas de Procesamiento de Lenguaje Natural (Natural Language Processing, NLP por sus siglas en inglés). El sistema recibirá archivos PDF como entrada, extraerá su contenido textual, identificará entidades y relaciones semánticas, y construirá una representación estructurada en forma de grafo de conocimiento, fundamentado estrictamente en la información contenida en los documentos proporcionados por el usuario.

Palabras clave – Extracción de información, grafos de conocimiento, modelos de lenguaje extensos, procesamiento de lenguaje natural.

1. Introducción

La cantidad de información disponible en formato digital ha crecido de manera exponencial en las últimas décadas. Una proporción significativa de esta información se encuentra almacenada en documentos no estructurados, siendo el formato PDF (Portable Document Format) uno de los más utilizados en ámbitos académicos, científicos, legales y empresariales [1]. A pesar de su amplia adopción, los archivos PDF presentan una limitación fundamental: su contenido está diseñado para la visualización humana, no para el procesamiento automático por parte de sistemas computacionales. Esta característica dificulta la extracción sistemática de entidades, conceptos y relaciones semánticas presentes en dichos documentos.

Los grafos de conocimiento (Knowledge Graphs, KG) constituyen una representación estructurada de la información que modela entidades como nodos y las relaciones entre ellas como aristas, permitiendo capturar la semántica subyacente de un dominio de manera explícita y navegable [2][3]. A diferencia de las bases de datos tradicionales, los grafos de conocimiento facilitan el descubrimiento de conexiones implícitas, la navegación conceptual y la inferencia de nueva información a partir de relaciones existentes. Grandes organizaciones tecnológicas como Google, Microsoft y Amazon han desarrollado grafos de conocimiento a escala masiva para potenciar sus servicios de búsqueda y recomendación [4].

Sin embargo, la construcción de grafos de conocimiento a partir de texto no estructurado continúa siendo un desafío abierto en el campo del Procesamiento de Lenguaje Natural (NLP). Las tareas involucradas incluyen el reconocimiento de entidades nombradas (Named Entity Recognition, NER), la extracción de relaciones (Relation Extraction, RE) y la resolución de correferencias, entre otras. Tradicionalmente, estas tareas se han abordado mediante modelos supervisados que requieren grandes volúmenes de datos etiquetados, lo cual limita su aplicabilidad a dominios específicos [5].

La aparición de los Modelos de Lenguaje Extensos (LLM) ha abierto nuevas posibilidades en este campo. Modelos como GPT, LLaMA y sus variantes han demostrado capacidades notables en tareas de comprensión y generación de lenguaje natural, incluyendo la extracción de información estructurada a partir de texto libre mediante técnicas de prompting y fine-tuning [6][7]. Estos avances permiten explorar enfoques para la construcción automatizada de grafos de conocimiento sin depender de esquemas rígidos predefinidos.

En el contexto de este Trabajo Terminal, se propone el desarrollo de un sistema que reciba archivos PDF como entrada, extraiga su contenido textual, y mediante el uso combinado de LLM y técnicas de NLP, genere un grafo de conocimiento personal. Este grafo estará estrictamente fundamentado en la información contenida en los documentos proporcionados por el usuario.

A continuación, se describen los trabajos y técnicas más relevantes relacionados con la generación de grafos de conocimiento a partir de texto:

I. Extracción de texto de documentos PDF

La extracción de texto de archivos PDF constituye la primera etapa crítica del proceso. Herramientas como Apache PDFBox, PyMuPDF y pdfplumber permiten obtener el contenido textual de documentos PDF, aunque enfrentan dificultades con formatos complejos que incluyen tablas, columnas múltiples e imágenes incrustadas [1]. Soluciones más recientes como Marker y Nougat emplean modelos de aprendizaje profundo para la conversión de PDF a formatos estructurados, logrando mayor fidelidad en la preservación de la estructura documental [8].

II. Construcción de grafos de conocimiento con LLM

Investigaciones recientes han explorado el uso de LLM para la extracción de tripletas (sujeto-predicado-objeto) directamente desde texto no estructurado. Trabajos como los de Wei et al. [6] y Wadhwa et al. [9] han demostrado que los LLM pueden realizar extracción de relaciones con desempeño competitivo frente a modelos supervisados, particularmente cuando se emplean estrategias de few-shot prompting. Frameworks como LlamaIndex y LangChain proporcionan abstracciones para la construcción de grafos de conocimiento utilizando LLM como motor de extracción [10].

III. Visualización y almacenamiento de grafos

Para el almacenamiento y consulta de grafos de conocimiento se emplean bases de datos orientadas a grafos como Neo4j, que utiliza el lenguaje de consulta Cypher, y Apache Jena para grafos basados en RDF [11]. En cuanto a la visualización, bibliotecas como D3.js, Cytoscape.js y vis.js permiten la representación interactiva de grafos en entornos web [12].

Estado del arte

Para comprender el panorama actual de las herramientas relacionadas con la extracción de información y la generación de grafos de conocimiento, se realizó un análisis comparativo que permitió identificar soluciones existentes con funcionalidades similares a las propuestas en este proyecto. A continuación, se presenta la Tabla 1 que compara herramientas comerciales y de código abierto, detallando su descripción, características y limitaciones.

Software / Proyecto	Descripción	Características	Limitaciones
LlamaIndex KG Module	Framework para construcción de índices de conocimiento con LLM.	Extracción de tripletas, integración con Neo4j, soporte multi-LLM.	Requiere configuración avanzada; no incluye extracción de PDF nativa.
Microsoft GraphRAG	Sistema de RAG basado en grafos de conocimiento.	Generación automática de comunidades, resumen jerárquico.	Orientado a búsqueda por consulta, no a visualización de grafo personal.
Diffbot NLP API	API comercial para extracción de entidades y relaciones.	Alta precisión, soporte multiidioma, API REST.	Servicio de pago; no genera grafo personal a partir de documentos del usuario.
spaCy + NER pipelines	Biblioteca de NLP con pipelines de extracción de entidades.	Código abierto, modelos preentrenados, extensible.	Requiere entrenamiento adicional para dominios específicos; no genera grafos directamente.
Solución Propuesta	Sistema integral de generación de grafos de conocimiento personales a partir de PDF.	Pipeline completo: extracción PDF, procesamiento NLP con LLM, generación y visualización de grafo personal.	Alcance limitado a documentos PDF proporcionados por el usuario.

Tabla 1. Resumen de productos y herramientas similares.

2. Objetivo general

Desarrollar un sistema que permita la generación de grafos de conocimiento personales a partir de documentos en formato PDF, mediante la integración de técnicas de extracción de texto, Procesamiento de Lenguaje Natural y Modelos de Lenguaje Extensos, produciendo una representación estructurada y navegable de las entidades, conceptos y relaciones semánticas contenidas en los documentos de entrada.

2.1 Objetivos específicos

2.1.1 Implementar un módulo de extracción de texto capaz de procesar archivos PDF con distintas estructuras documentales, preservando la coherencia textual del contenido original. Se evaluará mediante el porcentaje de fidelidad del texto extraído respecto al documento original (Character Error Rate, CER).

2.1.2 Diseñar e implementar un pipeline de procesamiento de lenguaje natural para la identificación de entidades, conceptos clave y relaciones semánticas a partir del texto extraído. Se evaluará mediante Precisión, Recall y F1-score sobre un conjunto de entidades y relaciones anotadas manualmente.

2.1.3 Integrar uno o más Modelos de Lenguaje Extensos como componente de extracción de información estructurada, generando tripletas (entidad-relación-entidad) fundamentadas en el contenido documental. Se evaluará mediante Triple Accuracy: porcentaje de tripletas verificables y correctas respecto al contenido del documento fuente.

2.1.4 Desarrollar el módulo de construcción del grafo de conocimiento, incluyendo la normalización de entidades, la resolución de correferencias y la consolidación de relaciones. Se evaluará mediante el Redundancy Rate (porcentaje de entidades duplicadas eliminadas) y Entity Coverage (porcentaje de entidades relevantes del documento representadas en el grafo).

2.1.5 Implementar una interfaz de visualización interactiva del grafo de conocimiento generado, que permita la navegación y exploración de las entidades y sus relaciones. Se evaluará mediante el cuestionario estandarizado SUS (System Usability Scale), ampliamente utilizado en trabajos de investigación para medir usabilidad.

2.1.6 Desarrollar una interfaz web que integre los módulos de carga de documentos, procesamiento y visualización del grafo resultante. Se evaluará mediante un checklist de pruebas funcionales con criterios de aceptación definidos por módulo (Task Completion Rate).

2.1.7 Realizar un conjunto de pruebas funcionales con documentos PDF de distintos dominios para validar la capacidad del sistema de generar grafos coherentes y fieles al contenido original. Se evaluará mediante F1-score sobre las tripletas generadas y una valoración de coherencia por parte de un experto en el dominio de cada documento.

3. Justificación

La transformación de datos no estructurados en representaciones estructuradas constituye uno de los desafíos centrales en el ámbito de la ingeniería de datos y el procesamiento de lenguaje natural. Los documentos en formato PDF, a pesar de ser uno de los medios más utilizados para la distribución de información académica, técnica y profesional, presentan una estructura orientada a la presentación visual que dificulta su procesamiento computacional automático. Esta limitación impide que la información contenida en estos documentos sea fácilmente accesible para tareas de análisis, relación y descubrimiento de conocimiento.

Actualmente, un usuario que desea comprender las relaciones entre los conceptos, entidades y temas presentes en uno o varios documentos PDF debe realizar este análisis de manera manual. Este proceso es inherentemente lento, propenso a omisiones y no escalable. La ausencia de herramientas que automaticen la extracción de información estructurada desde PDF y su representación en forma de grafo de conocimiento personal —estrictamente basado en el contenido del documento— representa una brecha funcional que este Trabajo Terminal busca atender.

Si bien existen frameworks y herramientas que abordan parcialmente las tareas de extracción de entidades o construcción de grafos, la mayoría requieren configuración técnica avanzada, no integran el procesamiento de PDF como etapa nativa del pipeline, o están orientados a la búsqueda por consulta (RAG) en lugar de la generación de un grafo personal explorable. La propuesta integra en un solo sistema el flujo completo desde la ingesta de documentos PDF hasta la visualización interactiva del grafo, fundamentando el resultado exclusivamente en el contenido proporcionado por el usuario.

Los beneficiarios directos de este sistema son estudiantes, investigadores y profesionales que trabajan con documentos extensos en formato PDF y necesitan identificar y comprender las relaciones entre los conceptos presentes en ellos. El sistema les permitirá generar una representación visual y navegable del contenido de sus documentos, facilitando la comprensión de la estructura conceptual subyacente.

El desarrollo del sistema implica la integración de múltiples áreas del conocimiento adquiridas a lo largo de la carrera: procesamiento de lenguaje natural, inteligencia artificial (modelos de lenguaje extensos), bases de datos orientadas a grafos, desarrollo web, diseño de interfaces y arquitectura de software. La complejidad técnica radica en la articulación de estas disciplinas en un pipeline coherente que produzca resultados fieles al contenido de entrada.

4. Productos o Resultados esperados

En este apartado se describen los productos finales del Trabajo Terminal, considerando el sistema a desarrollar, los documentos a generarse y las pruebas a realizar para validar los resultados.

Aplicación web: Desarrollo de una aplicación web que permita a los usuarios cargar documentos PDF, procesarlos mediante el pipeline de extracción y NLP, y visualizar el grafo de conocimiento resultante de manera interactiva.

Motor de extracción y construcción de grafos: Pipeline de procesamiento que integre la extracción de texto de PDF, la identificación de entidades y relaciones mediante LLM/NLP, y la construcción del grafo de conocimiento.

Documentación técnica: Descripción detallada de la arquitectura del sistema, los servicios de back-end, la base de datos de grafos, las APIs y los modelos utilizados.

Manual de usuario: Instrucciones detalladas sobre el uso de la aplicación web.

La arquitectura del sistema se estructura siguiendo un patrón de pipeline modular. El flujo inicia con el módulo de ingesta de documentos PDF, que recibe los archivos del usuario y extrae su contenido textual. El texto extraído pasa al módulo de procesamiento NLP, donde se realiza la segmentación, tokenización y preprocesamiento lingüístico. Posteriormente, el módulo de extracción con LLM genera las tripletas (entidad-relación-entidad). Finalmente, el módulo de construcción del grafo consolida las tripletas, normaliza las entidades y almacena el resultado en una base de datos de grafos, que es consultada por la interfaz de visualización.



Figura 1. Arquitectura del sistema.

5. Metodología

La metodología elegida para el presente Trabajo Terminal es el Modelo de Prototipado Evolutivo. Esta metodología es la más adecuada debido a la naturaleza exploratoria del proyecto: la generación de grafos de conocimiento a partir de documentos PDF involucra componentes de inteligencia artificial y procesamiento de lenguaje natural cuyos requisitos funcionales no pueden definirse completamente desde el inicio, ya que dependen de la calidad de la extracción de texto, la precisión del LLM y la estructura variable de los documentos de entrada.

El Prototipado Evolutivo parte de la construcción de un prototipo inicial funcional que se refina y extiende de forma progresiva mediante ciclos sucesivos de desarrollo, evaluación y retroalimentación. A diferencia del prototipado desechable, el prototipo evolutivo no se descarta: cada versión constituye la base sobre la que se construye la siguiente, incorporando nuevos módulos y mejoras derivadas de la evaluación del prototipo anterior. De esta forma, el sistema crece de manera orgánica hasta alcanzar la funcionalidad completa requerida.

El desarrollo se estructurará en cuatro prototipos evolutivos distribuidos en las dos etapas del Trabajo Terminal. Los prototipos 1 y 2 (correspondientes a TT1) se enfocarán en la construcción de la infraestructura web, la extracción de texto de PDF y el pipeline inicial de NLP, generando un prototipo funcional capaz de extraer y mostrar entidades desde un documento. Los prototipos 3 y 4 (correspondientes a TT2) abordarán la integración del LLM para la extracción de tripletas, la construcción del grafo de conocimiento y la visualización interactiva, evolucionando el sistema hasta su versión final validada.

5.1. Etapa 1: Trabajo Terminal I (Infraestructura y Extracción)

El objetivo de esta etapa es construir los primeros prototipos funcionales que establezcan la infraestructura tecnológica, el módulo de extracción de texto de PDF y el pipeline inicial de procesamiento NLP.

5.1.1. Prototipo 1: Infraestructura Web y Módulo de Extracción de PDF

Objetivo: Construir el primer prototipo funcional que integre la arquitectura base de la aplicación web (frontend y backend) y el módulo de extracción de texto a partir de documentos PDF.

Actividades principales: diseño y creación de la base de datos de grafos; implementación del backend con API REST para la gestión de documentos; desarrollo de la interfaz de carga de archivos PDF; implementación del módulo de extracción de texto con manejo de distintas estructuras documentales.

Evaluación del prototipo: Se verificará que el prototipo permita cargar documentos PDF y visualizar el texto extraído en la interfaz. Se evaluará la fidelidad del texto extraído respecto al documento original. Los hallazgos retroalimentarán el desarrollo del siguiente prototipo.

5.1.2. Prototipo 2: Pipeline de NLP y Extracción Inicial de Entidades

Objetivo: Evolucionar el prototipo anterior incorporando el pipeline de procesamiento de lenguaje natural para la segmentación textual, la identificación de entidades y la extracción preliminar de relaciones.

Actividades principales: implementación de la segmentación y preprocesamiento del texto; integración de modelos de NER para la identificación de entidades; desarrollo de las primeras pruebas de extracción de relaciones; documentación técnica de la etapa.

Evaluación del prototipo: Se validará que el sistema identifique entidades relevantes del texto extraído. Se analizará la cobertura de los modelos de NER en distintos dominios. Los resultados orientarán los ajustes para la integración del LLM en la siguiente etapa.

5.2. Etapa 2: Trabajo Terminal II (LLM, Construcción de Grafo e Integración)

En esta etapa se evolucionan los prototipos para integrar los Modelos de Lenguaje Extensos como motor principal de extracción de tripletas y completar la construcción y visualización del grafo de conocimiento.

5.2.1. Prototipo 3: Integración de LLM y Construcción del Grafo

Objetivo: Evolucionar el prototipo incorporando el LLM como componente de extracción de tripletas y el módulo de construcción y consolidación del grafo de conocimiento.

Actividades principales: diseño de prompts para la extracción de tripletas con LLM; implementación del módulo de normalización de entidades y resolución de correferencias; construcción del grafo de conocimiento en la base de datos de grafos; validación técnica de la coherencia del grafo generado.

Evaluación del prototipo: Se verificará que las tripletas generadas estén fundamentadas en el contenido del documento original. Se evaluará la coherencia del grafo construido y se ajustarán los prompts y parámetros del LLM según los resultados obtenidos.

5.2.2. Prototipo 4: Visualización, Integración Final y Validación

Objetivo: Construir la versión final del sistema incorporando la interfaz de visualización interactiva del grafo, integrando todos los módulos y realizando las pruebas de validación con documentos reales.

Actividades principales: desarrollo de la visualización interactiva del grafo; integración completa de todos los módulos del sistema; pruebas funcionales con documentos PDF de distintos dominios; elaboración del manual de usuario y documentación final.

Evaluación del prototipo: Se realizarán pruebas con documentos de distintos dominios para validar la capacidad funcional del sistema. Se recopilará retroalimentación y se realizarán los ajustes finales previos a la entrega.




Figura 2. Metodología del Modelo de Prototipado Evolutivo.

6. Cronograma

Nombre del alumno: González Arellano Jesús Ángel TT No.: _____

Título del TT: Generación de Grafos de Conocimiento a partir de Documentos en Formato PDF mediante LLM y NLP

Actividad	AGO	SEP	OCT	NOV	DIC	ENE	FEB	MAR	ABR	MAY	JUN
Análisis y diseño de la arquitectura del sistema											
Prototipo 1: Módulo de extracción de texto de PDF											
Prototipo 2: Pipeline de NLP y extracción de entidades											
Evaluación de TT I											
Prototipo 3: Integración de LLM y construcción del grafo											
Prototipo 3: Normalización y consolidación del grafo											
Prototipo 4: Visualización interactiva del grafo											
Prototipo 4: Pruebas y validación											
Documentación técnica y manual de usuario											
Evaluación de TT II											


7. Referencias

- [1] B. Yalniz, S. Belongie, "Parsing PDF Documents for Semantic Information," en Proc. ICDAR, 2009.
- [2] A. Hogan et al., "Knowledge Graphs," ACM Computing Surveys, vol. 54, no. 4, pp. 1–37, 2021.
- [3] L. Ehrlinger y W. Wöß, "Towards a Definition of Knowledge Graphs," en Proc. SEMANTiCS, 2016.
- [4] A. Singhal, "Introducing the Knowledge Graph," Google Official Blog, 2012. [En línea]. Disponible: <https://blog.google/products/search/introducing-knowledge-graph-things-not/>
- [5] D. Nadeau y S. Sekine, "A survey of named entity recognition and classification," Lingvisticae Investigationes, vol. 30, no. 1, pp. 3–26, 2007.
- [6] X. Wei et al., "Zero-Shot Information Extraction via Chatting with ChatGPT," arXiv preprint arXiv:2302.10205, 2023.
- [7] W. X. Zhao et al., "A Survey of Large Language Models," arXiv preprint arXiv:2303.18223, 2023.
- [8] L. Blecher et al., "Nougat: Neural Optical Understanding for Academic Documents," arXiv preprint arXiv:2308.13418, 2023.
- [9] S. Wadhwa et al., "Revisiting Relation Extraction in the Era of Large Language Models," en Proc. ACL, 2023.
- [10] LlamaIndex, "Knowledge Graph Index," 2024. [En línea]. Disponible: <https://docs.llamaindex.ai>

8. Alumnos y Directores

González Arellano Jesús Ángel. - Alumno de la carrera de Ing. en Sistemas Computacionales en ESCOM, Especialidad Sistemas, Boleta: 2022630690, Tel. 2212613339, email: chuchisamtkd@gmail.com.

CARÁCTER: Confidencial
FUNDAMENTO LEGAL: Artículo 11 Fracc. V y Artículos 108, 113 y 117 de la Ley Federal de Transparencia y Acceso a la Información Pública.
PARTES CONFIDENCIALES: Número de boleta y teléfono.

Firma: 

Rosas Carrillo Ary Shared. - Dr. en Ingeniería de Sistemas Robóticos y Mecatrónicos por el IPN (2025), Maestría en Tecnología de Cómputo por el IPN (2016), Ingeniería en Sistemas Computacionales por el IPN (2013). Áreas de interés: Cómputo evolutivo, algoritmos bioinspirados, análisis y diseño de sistemas. Centro de Innovación y Desarrollo Tecnológico en Cómputo, Tel. 5729-6000 ext. 52524, email: arosasc@ipn.mx.

Firma: 

Ramírez Morales Mario Augusto. - M. En C. En Ingeniería Eléctrica del CINVESTAV-IPN en 2008, ISC por la ESCOM en 2003. Áreas de interés: Aprendizaje máquina, Large Language Models. CIDETEC-IPN, Tel. 57296000 ext., email: mramirezmo@ipn.mx

Firma: 